

불면증 발병 예측 분석

로지스틱 회귀 모형을 이용한 분석



2019380703 임찬희
2019380503 정윤재

CONTENTS

1

주제선정이유

- 주제선정이유
- 기대효과

2

데이터 소개

- 데이터 수집
- 데이터 변수 설명

3

데이터 전처리

- 결측치와 이상치 대체
- 변수 범주화

4

분석 과정

- 변수 선택
- 적합도 검정
- 예측력 평가

5

모델 구축 및 결과 해석

- 모델 구축
- 결과 해석

주제 선정 이유

출처: 동아일보

현재 국내 불면증 환자는 약 70만 명에 이른다. 건강보험심사평가원의 ‘국민관심질병통계’에 따르면 불면증 환자는 2021년 기준 68만4560명이다. 2017년 56만855명에서 4년 만에 12만 명 훌쩍 넘게 증가했다. 불면증은 △잠들기 어렵고 △도중에 깨면 다시 잠들기 어려우며 △잠 때문에 우울·과민·짜증을 호소하고 △잠이 모자라 일상생활에 지장을 받으며 △이런 증상이 일주일에 3일 이상, 3개월간 지속될 때 진단할 수 있다. 병원 진료를 받지 않은 경우까지 합치면 불면증 환자는 훨씬 더 많을 것으로 추정된다.


기대 효과

로지스틱 회귀분석을 통해 불면증 발병에 영향을 미치는 요인을 식별하고 로지스틱 모델을 구축함으로써, 불면증 발병의 주요 요인들을 식별하여 예방하고 개인화된 건강 서비스를 제공할 수 있다.

단위: 명

■ 환자 수

불면증 환자 증가 추이




데이터 출처: 통계청

불면증 발병 데이터

데이터 수집 - kaggle , 12개의 변수 / 70001개의 데이터


	A	B	C	D	E	F	G	H	I	J	K	L	M
1	id	age	weight	height	sex	stress	doctor	sport	pernicious	pernicious	ubp	lbp	insomnia
2	0	50.35729	62	168	2	1	1	1	0	0	110	80	0
3	1	55.38125	85	156	1	3	1	1	0	0	140	90	1
4	2	51.62765	64	165	1	3	1	0	0	0	130	70	1
5	3	48.24914	82	169	2	1	1	1	0	0	150	100	1
6	4	47.8412	56	156	1	1	1	0	0	0	100	60	0
7	8	59.99726	67	151	1	2	2	0	0	0	120	80	0
8	9	60.54209	93	157	1	3	1	1	0	0	130	80	0
9	12	61.83162	95	178	2	3	3	1	0	0	130	90	1
10	13	48.37235	71	158	1	1	1	1	0	0	110	70	0
11	14	54.30253	68	164	1	1	1	0	0	0	110	60	0
12	15	61.68378	80	169	1	1	1	1	0	0	120	80	0
13	16	51.51266	60	173	2	1	1	1	0	0	120	80	0
14	18	40.49555	60	165	2	1	1	0	0	0	120	80	0
15	21	54.23409	78	158	1	1	1	1	0	0	110	70	0
16	23	39.78645	95	181	2	1	1	1	1	1	130	90	0

데이터 변수 설명




- age - 나이
- weight- 몸무게
- height- 신장
- sex - 성별
- stress - 지난 달 동안의 스트레스 수준 (1, 2, 3 - 높은 값은 더 큰 스트레스를 나타냄)
- doctor - 이전에 의사를 방문한 상대적인 횟수 (1, 2, 3 - 높은 값은 더 많은 방문을 나타냄)
- sport - 개인이 신체적으로 활동적인지 여부 (binary)
- pernicious_1 - 개인이 나쁜 습관이 있는지 여부 (binary)
- pernicious_2 - 개인이 다른 나쁜 습관이 있는지 여부 (binary)
- UBP/LBP - 혈압의 상/하부 (mmHg)
- insomnia - 목표, 개인이 수면 장애가 있는지 여부 (binary)


이상치 제거 및 대체값 수정



5000이상의 값과 음수 값 제거(ubp, lbp)



5000이상의 값과 음수 값 제거 후



ubp : 180이상 > 180, 90이하 > 90
lbp : 110이상 > 110, 60이하 > 60

변수 범주화

age 변수를 age_category 변수로 범주화

20대 -> 1
30대 -> 2
40대 -> 3
50대 -> 4
60대 -> 5

	weight	height	sex	stress	doctor	sport	pernicious_1	pernicious_2	ubp	lbp	insomnia	age_category
1	62	168	2	1	1	1	0	0	110	80	0	4
2	85	156	1	3	1	1	0	0	140	90	1	4
3	64	165	1	3	1	0	0	0	130	70	1	4
4	82	169	2	1	1	1	0	0	150	100	1	3
5	56	156	1	1	1	0	0	0	100	60	0	3
6	67	151	1	2	2	0	0	0	120	80	0	4



변수 선택

1. 초기 변수(model0)

```
Response: insomnia
```

	LR	Chisq	Df	Pr(>Chisq)	
weight	273.1	1	< 2.2e-16	***	
height	12.6	1	0.0003943	***	
sex	0.6	1	0.4254621		
stress	1127.0	1	< 2.2e-16	***	
doctor	42.5	1	7.054e-11	***	
sport	108.4	1	< 2.2e-16	***	
pernicious_1	20.8	1	5.172e-06	***	
pernicious_2	23.5	1	1.273e-06	***	
ubp	4269.9	1	< 2.2e-16	***	
lbp	152.1	1	< 2.2e-16	***	
factor(age_category)	1230.0	4	< 2.2e-16	***	

2. 성별 변수 제거 후 모형(model1)

```
Response: insomnia
```

	LR	Chisq	Df	Pr(>Chisq)	
weight	273.0	1	< 2.2e-16	***	
height	18.8	1	1.449e-05	***	
stress	1129.3	1	< 2.2e-16	***	
doctor	42.5	1	7.248e-11	***	
sport	108.4	1	< 2.2e-16	***	
pernicious_1	24.2	1	8.471e-07	***	
pernicious_2	23.9	1	1.005e-06	***	
ubp	4269.9	1	< 2.2e-16	***	
lbp	151.8	1	< 2.2e-16	***	
factor(age_category)	1229.4	4	< 2.2e-16	***	

변수 선택

3. age_factor의 유의성 확인

factor(age_category)2	8.158e+00	5.822e+01	0.140	0.888556
factor(age_category)3	8.457e+00	5.822e+01	0.145	0.884505
factor(age_category)4	8.376e+00	5.822e+01	0.144	0.885602
factor(age_category)5	8.602e+00	5.822e+01	0.148	0.882529

model1에서 나이 변수가 유의성이 없다는 것을 확인
하여 age_factor를 제외하고 model1_1을 구축



최종 모델 선택
model1_1

model1_1의 다중공선성 확인

	GVIF	DF	GVIF^(1/(2*DF))
weight	1.157398	1	1.075824
height	1.146887	1	1.070928
stress	1.290764	1	1.136118
doctor	1.279181	1	1.131009
sport	1.002612	1	1.001305
pernicious_1	1.165156	1	1.079424
pernicious_2	1.137614	1	1.066590
ubp	1.685862	1	1.298408
lbp	1.672632	1	1.293303

- VIF값을 통해 다중공선성을 확인 해본 결과 모든 변수의 VIF값이 2이하임
- 다중공선성이 문제 없다는 것을 확인

model1_1의 적합도 검정

피어슨 카이제곱 검정

Pearson's Chi-squared test

```
data: model1_1$fitted.values and insomnia$insomnia  
X-squared = 49057, df = 44200, p-value < 2.2e-16
```

가능도비 검정

Analysis of Deviance Table

Model 1: insomnia ~ 1

Model 2: insomnia ~ weight + height + stress + doctor + sport + pernicious_1 +
pernicious_2 + ubp + lbp

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	69000	95648			
2	68991	79023	9	16626	< 2.2e-16 ***


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

model1_1의 적합함을 확인

model1_1의 예측력 평가

AIC / AUC	79864.75 / 0.78
다중상관계수	0.484
Deviance	79844.75
민감도/특이도/정확도	0.66 / 0.79 / 0.73

ROC곡선 확인



모델 구축

```
Call:
glm(formula = insomnia ~ weight + height + stress + doctor +
     sport + pernicious_1 + pernicious_2 + ubp + lbp, family = binomial,
     data = insomnia)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-8.3446997	0.2005562	-41.608	< 2e-16	***
weight	0.0112029	0.0006752	16.591	< 2e-16	***
height	-0.0074119	0.0011250	-6.589	4.44e-11	***
stress	0.5375475	0.0152840	35.171	< 2e-16	***
doctor	-0.0972157	0.0173891	-5.591	2.26e-08	***
sport	-0.2285385	0.0214721	-10.644	< 2e-16	***
pernicious_1	-0.1925260	0.0329730	-5.839	5.25e-09	***
pernicious_2	-0.2302567	0.0413596	-5.567	2.59e-08	***
ubp	0.0546651	0.0008610	63.494	< 2e-16	***
lbp	0.0178140	0.0013466	13.229	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 96984 on 69958 degrees of freedom
 Residual deviance: 79845 on 69949 degrees of freedom
 AIC: 79865

Number of Fisher Scoring iterations: 4

유의하지 않은 변수

나이와 성별

유의한 변수

몸무게, 키, 스트레스, 병원 방문 횟수,
 운동, 나쁜 습관1, 나쁜 습관2, 상부 혈압, 하부 혈압

결과 해석

insomnia(Y) =

$$-8.35 + 0.01\text{weight} - 0.01\text{height} + 0.54\text{stress} - 0.09\text{doctor} - 0.23\text{sport} - 0.19\text{-pernicious_1} - 0.23\text{pernicious_2} + 0.05\text{ubp} + 0.01*\text{lbp}$$

몸무게 1kg 증가 약 1.13% 증가

스트레스 1지수 증가 약 71.17% 증가

상부 혈압 1단위 증가 약 5.6% 증가

하부 혈압 1단위 증가 약 1.8% 증가

키 1cm 증가 약 0.74% 감소

병원 방문 1단위 증가 약 9.24% 감소

나쁜 습관1,2 (밤샘 습관,
스마트폰 사용습관)
1단위 증가 약 16.7% 감소
약 20.6% 감소

운동량 1단위 증가 약 20.3% 감소



Thank You!

감사합니다.